

LLM의 민감 정보 유출 방지 기술의 동향과 한계

박준영*, 고남현*, 김준식*, 김도영*, 윤주범**

*세종대학교 (학부생), **세종대학교 (지도교수)

Trends in Sensitive Information Leakage Prevention Technologies in LLM

Junyeong Park*, Namhyun Ko*, Junsik Kim*, Doyoung Kim*, Jubum Yun**

*Sejong University(Undergraduate student),

**Sejong University(Professor)

요약

요약 작성.

I. 서론

OpenAI와 Google 등을 필두로 한 상용 LLM이 생산성 증가로 이어지면서 많은 기업들이 LLM 모델을 사내에서 사용할 수 있도록 전환하였다. 그러나 기업 내부의 민감 정보 혹은 직원의 개인정보가 상용 LLM 벤더에게 유출되는 사고가 잇따라 발생하면서 기업들은 상용 LLM의 사내 사용을 금지하거나 통제하여 데이터 유출을 방지하고, 사내 로컬 LLM을 사용하도록 유도하는 방식으로 전환하였다. 그러나 상용 LLM의 성능과 편리성으로 인해 많은 내부 직원들이 내규를 따르지 않고 상용 LLM을 계속해서 이용하고있는 실정이며, 이는 기업의 통제에서 벗어나 몰래 외부망의 AI 서비스를 이용한다고 하여 “Shadow AI”라는 이름을 가지게 되었다. Netskope에 따르면 Shadow AI 문제는 계속해서 증가하고 있으며, 오히려 LLM 사용자 증가 추이와 Shadow AI 사고 증가 추이 간 통계가 일치하지 않아 보고되지 않은

Shadow AI 문제가 더욱 클 것이라고 예측한다 [1. Netskope 2025 AI 데이터 보고서]. 이에 따라 기업들은 직원들의 민감 정보 외부 유출 방지 기술에 대한 수요가 증가하고 있다.

1.1 민감 정보

민감 정보란 개인식별 가능 정보 (Personally Identifiable Information, PII), 사내 기밀 문건, 국가 기밀 등 법령, 시행령, 혹은 내규로써 정의한 외부에 알려져서는 안되는 모든 형태의 정보를 일컫는다.

1.2 민감 정보 유출의 범위

LLM 사용 환경에서의 민감 정보 유출은 입력과 출력의 두 가지 측면을 포함하는 개념이다. 입력 측면은 사용자가 프롬프트나 업무로써 LLM 혹은 AI 에이전트에게 민감 정보를 전달하여 해당 데이터가 외부 서버 및 데이터베이스에 저장되는 것을 말한다. 출력 측면은 AI 모델이 답변을 생성하는 과정에서 선제적으로 학

[입력과 출력 두 가지 측면에 무엇이 있는지를 정리한 표]

습한 혹은 검색 증강 생성과 같이 외부 데이터베이스에서 검색한 민감 정보를 답변에 포함하여 해당 정보에 대한 접근 권한이 없는 사용자에게 정보를 유출하는 것을 말한다.

II. 연구 범위

본 논문은 앞서 서술한 정의를 기반으로 민감 정보 유출 방지 기술을 제안하는 연구를 심층적으로 조사하여 최신 연구의 주요 동향과 한계점을 정리한다. 또한, 도출한 한계점이 보안 기술 전반에 걸쳐 나타난다는 유사성을 제기함으로써 AI 시대의 올바른 데이터 보호 기술 또한 어느 보안 분야와 마찬가지로 비슷한 방향의 기술적 고민과 타파가 필요함을 제시한다.

III. 결론

본 논문에서는

[참고문헌]

- [1] D.S.Milojicic, V.Kalogeraki, R.Lukose, K.Nagaraja, J.Pruyne, B.Richard, S.Rollins and Z.Xu, Peer to Peer Computing, HP Laboratories Palo Alto HPL-2002-57, March, 2002.