

에이전틱 AI 환경에서의 데이터 과다 수집 위협 분석

김준식*, 고남현*, 김도영*, 박준영*, 윤주범*

*세종대학교 (대학생, 교수)

Analysis of Data Over-collection Threats in Agentic AI Environments

Jun-Sik Kim*, Nam-Hyun Ko*, Do-Yeong Gim*, Jun-Yeong Park*,
Ju-Beom Yun*

*Sejong University(Ungraduate student, Professor)

요 약

최근 에이전틱 AI(Agentic AI)는 단순한 텍스트 생성을 넘어 외부 도구를 자율적으로 활용하는 형태로 진화하고 있다. 이에 따라 MCP(Model Context Protocol) 환경이 확산되고 있으나, 이는 기존 보안 체계가 탐지하지 못하는 새로운 데이터 유출 위협을 불러오고 있다.

본 논문은 이러한 위협이 도구의 과도한 데이터 제공과 LLM의 문맥적 프라이버시 인식 부재에서 기인함을 분석한다. 특히 에이전트 도구들이 범용성을 위해 필요 이상의 데이터 스키마를 반환하는 Broad Read 방식은 LLM이 민감 정보를 합성하거나 유출하는 데이터 과다 수집의 원인이 된다. 실제 주요 MCP 서버를 조사한 결과, 설계의 약 42.8%가 이러한 구조적 과다 수집 위협을 내포하고 있으며, 기존의 출력 기반 모니터링으로는 이를 충분히 탐지하지 못한다. 이미 사용 중인 모든 API와 데이터베이스를 Atomic Read 방식으로 재설계하는 것은 시스템 효율성과 비용 측면에서 불가능에 가깝다. 따라서 도구 자체를 수정하는 대신, MCP 서버와 에이전트 사이에 문맥 인식 필터(Context-Aware Filter) 레이어를 구축하여 사용자 프롬프트의 의도를 분석하는 방식이 필요함을 제안한다.

I. 서론

1.1 배경

최근 대규모 언어 모델(Large Language Model, LLM)은 단순한 텍스트 생성기를 넘어, 외부 도구를 자율적으로 호출하고 조합하여 복잡한 현실 세계의 작업을 수행하는 Agentic AI로 빠르게 진화하고 있다.

이에 따라 시스템이 다양한 외부 API에 접근할 수 있도록 돕는 MCP와 같은 도구 연동 환경이 확산되면서, 단일 에이전트의 다중 도구 오케스트레이션이나 다중 에이전트 협업 시스템은 엔터프라이즈 환경의 핵심 아키텍처로 자리 잡았다. 그러나 이러한 도구 호출 등의 확장된 기능성은 에이전트 시스템 내의 기존 보안 체계로 탐지할 수 없는 새로운 데이터 유출 및 프라이버시 침해 위협을 불러오고 있다.

II. 관련 연구

첫 번째는 도구의 과도한 데이터 제공과 LLM의 문맥적 프라이버시 인식 부재이다. AgentRaft[1]에 따르면 현재 에이전트 도구들은 다양한 요청에 범용적으로 대응하기 위해 작업에 필요한 최소한의 데이터만 반환하지 않고 불필요한 넓은 범위의 데이터 스키마를 반환하게 된다. 반면 LLM은 복잡한 작업 흐름 속에서 특정 데이터가 필요한 정보인지 민감 정보인지 문맥적으로 판단하지 못하여 유입된 과잉 정보가 제 3자에게 유출되는 데이터 과다 노출(Data Over-Exposure, DOE)이 발생한다.

Qiao 등[2]은 에이전트가 다중 도구를 연쇄 호출하여 수집한 과편화된 비민감 데이터를 결합, 단일 출처로는 식별 불가능한 민감 정보를 합성하는 위험성을 지적하였다. 이는 악의적 공격보다 사용자의 과업을 최적으로 완수하려는

모델의 유용성과 고도화된 추론 능력에 기인한다. 특히 모델의 지능이 높을수록 정보 간의 암시적 연결 고리를 더 정교하게 식별하여 유출률이 상승하는 결과를 기록하였으며, 이는 에이전트의 성능 향상이 프라이버시 침해를 가속화하는 구조적 취약점이 됨을 시사한다.

한편, AgentLeak[3]은 에이전트가 외부 도구 호출 시 입력 매개변수를 무비판적으로 신뢰함으로써 발생하는 민감 정보 유출 문제를 분석하였다. 특히 최종 사용자에게 전달되는 출력물만 모니터링하는 기존 보안 체계는 도구 호출이면서 발생하는 유출의 41.7%를 탐지하지 못함을 실증하였다. 이는 도구 연동 환경에서 발생하는 유출이 단순한 결과값 노출을 넘어, 에이전트와 도구 간의 중간 데이터 흐름에서 은밀하게 발생함을 시사하며, 출력 기반 모니터링의 구조적 한계를 지적한다.

결과적으로, 현재 Agentic AI 환경에서 발생하는 데이터 유출은 외부 공격 뿐만 아니라, 기능적 유용성을 위해 도구 간에 과도한 데이터를 주고받도록 설계된 에이전트의 구조적 결함과 '데이터 최소화' 원칙의 부재에서 발생한다. 따라서 기존의 출력 기반 모니터링을 넘어, 현재 MCP Tool를 통해 얼마나 데이터를 과도하게 수집하도록 설계되어 있는지 구체적으로 분류 및 측정하고, 문맥을 파악하여 통제할 수 있는 새로운 차원의 동적 방어 메커니즘이 필요하다.

III. 본론

3.1 도구 호출 인터페이스의 분류

에이전트가 외부 환경과 상호작용하는 MCP 환경에서, 데이터 수집 도구는 반환되는 정보에 따라 2가지로 분류하였다.

- Broad Read : 특정 개체와 관련된 모든 속성을 묶어서 반환
- Atomic Read : 특정 목적에 부합하는 최소 단위의 데이터만 반환

3.2. Broad Read 도구 분석

Broad Read 도구는 단일 요청에 대해 객체의

전체 속성을 묶어서 반환하는 특징을 가진다. 하지만 이는 LLM에게 현재 작업과 상관없거나 더 넓은 범위의 필드를 인지시킨다. 이는 단순히 민감 정보가 포함된 내용을 유출할 수 있을 뿐만 아니라, LLM이 의도치 않은 필드들을 보고 잘못된 추론하여 민감 정보를 합성해내는 촉매제로 작용될 수 있다.

3.3 MCP 도구 설계 조사

표 1은 현재 사용되고 있는 주요 MCP 서버 7종의 도구를 조사한 결과이다.

MCP Server	Total	Read (Atomic)	Read (Broad)	Broad Read Rate
google-calendar	28	1	9	32.1%
notion-mcp-server	22	7	6	31.8%
server-postgres	4	2	1	50%
github	88	19	37	42%
supabase	30	6	14	46%
stripe	25	2	11	44%
HubSpot	7	0	6	85%
전체 합계	208	35	89	42.8%

(표 1) MCP 서버 broad read 기능 조사

대부분의 MCP 서버 개발자들이 재사용성과 개발 편의성을 위해 정보의 최소화 원칙을 지키지 못하고 있으며, 에이전트가 단 한 번의 도구 호출만으로도 민감 정보를 포함한 불필요한 정보까지 대량으로 확보될 수 있는 환경이라고 볼 수 있다.

3.4 구조적 한계와 대안

데이터 최소화 원칙에 따라 모든 도구를 Atomic Read로 바꾸는 것이 이상적이지만, 실제 시스템에 적용하기에는 현실적인 문제점들이 존재한다. 먼저 도구를 지나치게 세분화하면

관리해야 할 도구의 수가 늘어나 관리가 어려워지며, 에이전트가 수많은 도구 중 하나를 선택시, 엉뚱한 도구를 호출할 가능성이 높아진다. 또한 이미 기업 내에서 사용 중인 API나 DB를 고치는 것도 불가능에 가깝다.

따라서 기존의 DLP(Data Loss Prevention) 솔루션의 범위를 MCP 도구 호출에서도 적용해야 하며, 단순히 키워드나 패턴을 보고 입출력을 필터링하는 것 뿐만 아니라, MCP 환경에서는 사용자 프롬프트의 의도를 분석하고 파악하는 문맥적 필터링이 필요할 것으로 시사된다.

IV. 결론

본 논문에서는 Agentic AI 환경에서의 MCP Tool의 Read Tool 설계 중 약 42.8 %가 구조적인 과다 수집 위험을 내포하고 있음을 실증하였다. 이는 단순한 우발적 유출이 아닌 개발편의 중심 아키텍처로 인한 취약점이라고 볼 수 있다. 하지만 현실적으로 모든 API를 원자적으로 재설계하는 것은 시스템 효율성과 비용 측면에서 불가능에 가깝다. 따라서 향후 에이전트에서의 발생하는 데이터 유출 방지는 도구의 개별적 수정이 아닌 MCP 서버와 에이전트 사이에 Context-Aware Filter 레이어를 통한 문맥에 기반한 필터링 기능 보완에 집중해야 할 것으로 예상된다.

Benchmark for Privacy Leakage in Multi-Agent LLM Systems, arXiv:2602.11510, 2026.

[참고문헌]

- [1] Y. Lin, J. Wu, Y. Nan, X. Wang, X. Zhang and Z. Zheng, AgentRaft: Automated Detection of Data Over-Exposure in LLM Agents, arXiv:2603.07557, 2026.
- [2] Y. Qiao, D. Liu, H. Yang, W. Zhou and S. Hu, Agent Tools Orchestration Leaks More: Dataset, Benchmark, and Mitigation, arXiv:2512.16310, 2026.
- [3] F.E. Yagoubi, G. Badu-Marfo and R.A. Mallah, AgentLeak: A Full-Stack